

Lire les resultats

Ecran final

A la fin du run, vous obtenez:

- Score global
- Score obligatoire
- Note globale (A a F)
- Note obligatoire (A a F)
- Verdict

Difference entre score global et score obligatoire

- Score global: toutes les evaluations executees
- Score obligatoire: uniquement les tiers obligatoires pour le profil

Le score obligatoire est la reference principale pour juger le modele.

Echelle de notes

- A: $\geq 90\%$
- B: 70-89%
- C: 50-69%
- D: 30-49%
- F: $< 30\%$

Regle du verdict

- $\geq 80\%$ obligatoire: MODELE RECOMMANDE
- 50-79% obligatoire: MODELE PARTIEL - RESERVES
- $< 50\%$ obligatoire: MODELE NON RECOMMANDE

Lecture des resultats par tier

Chaque tier affiche:

- un tableau des taches
- score tache par tache

- note tache
- etat du tier (reussi/echechs)

Rapport Markdown genere

Le rapport contient:

- recap profil/date/modele
- detail de chaque tache
- code produit par le modele
- details des evaluations pass/fail
- sortie brute API (section repliable)
- tableau final score + note + verdict

Nommage des rapports

Format:

- rapportv3nommodele_profil.md
- rapportv3nommodeleprofiltierX.md (si vous ciblez un tier unique)

Le nom du modele est nettoye automatiquement pour rester compatible fichier.

Logs: a quoi ils servent

Le fichier de logs enregistre notamment:

- config effective du run
- hash du prompt par tier
- duree API
- statut parsing
- resultats d evaluation
- erreurs VM detaillees

Utilisation pratique:

- comparer 2 runs
- diagnostiquer un echec
- auditer un comportement inattendu